

Segunda Avaliação

Séries Temporais

Paulo Ricardo Seganfredo Campana

10 de abril de 2024

Considere a série temporal chicken, preço de aves inteiras, do pacote astsa. Este série é mensal com início em agosto de 2001 até julho de 2016, totalizando 180 observações.

1. Apresente a análise descritiva da série. Comente os resultados.


Primeiramente, a série tem frequência anual:

```
library(forecast)
library(ggplot2)

chicken <- astsa::chicken
frequency(chicken)
## [1] 12
```

Pelo gráfico da série podemos ver que o preço mensal em centavos de dólar por libra de galinha tem tendência crescente e pouca ou nenhuma sazonalidade. O preço médio varia de 61 centavos de dólar em dezembro de 2002 até 116 centavos em junho de 2015.

```
autoplot(chicken) +
  labs(x = "Tempo", y = "Preço")
```

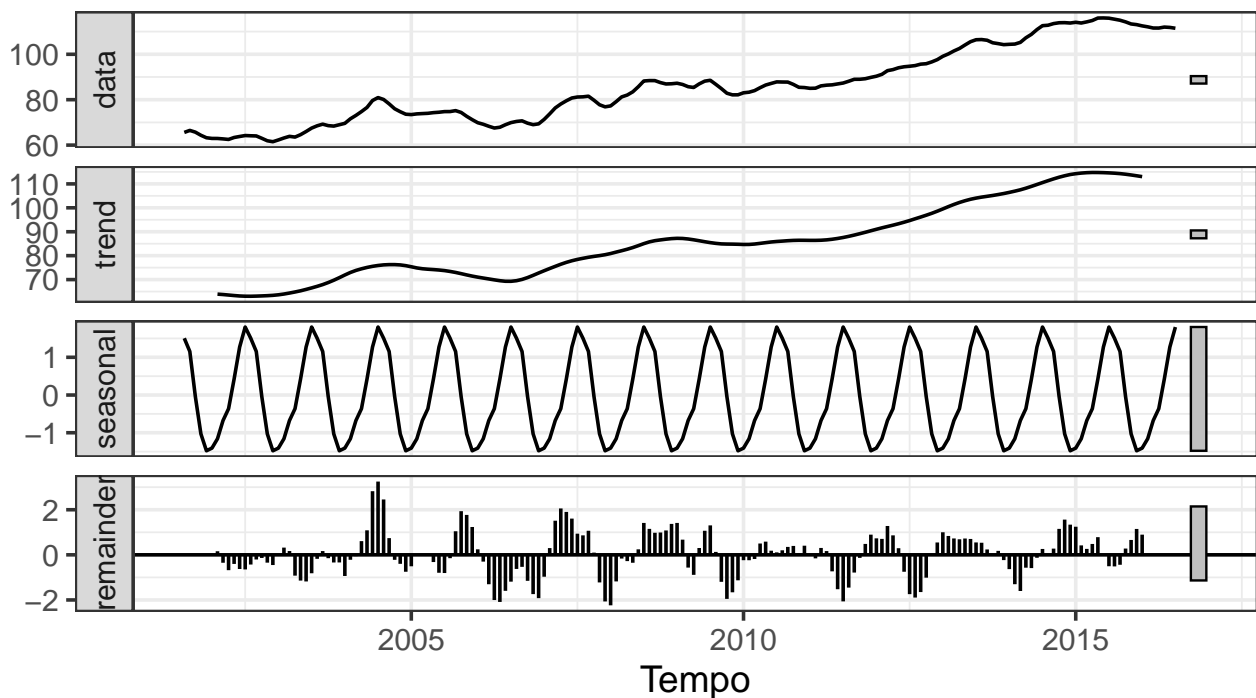


2. Explore e descreva todas as informações/características relevantes sobre a série em questão.

- (a) Apresente e analise os gráficos da série e os testes de hipótese que sejam relevantes para descrever a série. Vale ressaltar aqui que todos testes de hipóteses que você considerar, é preciso descrever as hipóteses nula e alternativa, nível de significância adotado e a conclusão do teste.

Isso é sugerido também pelo gráfico da decomposição clássica da série, separando os componentes de tendência, sazonalidade e aleatoriedade, a sazonalidade detectada pela decomposição é fraca: há uma discrepância de cerca de 3 centavos entre os pontos mínimos e máximos da sazonalidade, comparado com uma média global de cerca de 80 centavos.

```
decomp <- decompose(chicken, type = "additive")
autoplot(decomp) +
  labs(x = "Tempo", title = NULL)
```



Com um nível de significância de 5%, pelo p-valor, o teste KPSS rejeita a hipótese de estacionariedade e os testes de Dickey-Fuller e Phillips-Perron não rejeitam a hipótese de não estacionariedade, assim concluímos que a série tem tendência de fato.

```
tseries::kpss.test(chicken)$p.value
## [1] 0.01
tseries::adf.test(chicken)$p.value
## [1] 0.4109
tseries::pp.test(chicken)$p.value
## [1] 0.4398
```

Surpreendentemente, todos os testes de sazonalidade do pacote **seastests** rejeitam a hipótese de não haver sazonalidade na série, assim as pequenas mudanças de mês em mês são significantes.

```
seastests::qs(chicken)$pval
## [1] 6.268e-07
```

```
seastests::fried(chicken)$Pval
## [1] 3.765e-12
seastests::kw(chicken)$Pval
## [1] 1.966e-10
seastests::seasdum(chicken)$Pval
## [1] 4.53e-13
seastests::welch(chicken)$Pval
## [1] 6.887e-11
```

3. Utilize a função `auto.arima` do pacote `forecast` para selecionar os ordens dos modelos ARIMA/SARIMA.

- Quais os modelos ARIMA/SARIMA que minimizam os critérios AIC e BIC?
- Os coeficientes dos parâmetros dos modelos estimados são significativos? Comente, argumente e descreva passo a passo com detalhes.

Ajustando dois modelos com e sem sazonalidade, temos que aqueles que minimizaram os critérios de seleção foram um ARIMA de ordem (2,1,1) e um SARIMA de ordem (2,1,1)(0,0,1). O modelo SARIMA obteve melhores AIC e BIC em geral.

```
arima <- auto.arima(chicken, seasonal = FALSE)
sarima <- auto.arima(chicken, seasonal = TRUE)
arima
sarima
```

Series: chicken
ARIMA(2,1,1) with drift

Coefficients:

	ar1	ar2	ma1	drift
	1.353	-0.599	-0.457	0.268
s.e.	0.171	0.118	0.206	0.108

sigma^2 = 0.429: log likelihood = -176.8
AIC=363.5 AICc=363.8 BIC=379.4

Series: chicken
ARIMA(2,1,1)(0,0,1)[12] with drift

Coefficients:

	ar1	ar2	ma1	sma1	drift
	1.293	-0.537	-0.402	0.276	0.252
s.e.	0.222	0.154	0.257	0.069	0.143

sigma^2 = 0.396: log likelihood = -169.5
AIC=351 AICc=351.5 BIC=370.1

Pelo teste de significância dos coeficientes do modelo ARIMA, todos eles rejeitam a hipótese do seu coeficiente ser igual a 0, assim são todos significativos.

```
lmtest::coeftest(arima)
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1      1.353      0.171    7.92 2.4e-15 ***
## ar2     -0.599      0.118   -5.07 4.0e-07 ***
## ma1     -0.457      0.206   -2.22  0.027 *
## drift    0.268      0.108    2.49  0.013 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Porém no modelo SARIMA o coeficiente relacionado a médias móveis de ordem 1 e a constante aditiva do modelo não são significantes, com p-valores 0.1177 e 0.0777 respectivamente.

```
lmtest::coeftest(sarima)
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1      1.2933     0.2220   5.82 5.7e-09 ***
## ar2     -0.5375     0.1542  -3.48 0.00049 ***
## ma1     -0.4019     0.2569  -1.56 0.11766
## sma1      0.2756     0.0692   3.98 6.9e-05 ***
## drift      0.2518     0.1428   1.76 0.07771 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Deste modo, o modelo SARIMA deve ser refeito para que não haja coeficientes não significantes. A remoção destes parâmetros não impacta muito os critérios de seleção.

```
sarima <- Arima(
  chicken,
  order = c(2, 1, 0),
  seasonal = c(0, 0, 1),
  include.drift = FALSE,
)
sarima
## Series: chicken
## ARIMA(2,1,0)(0,0,1)[12]
##
## Coefficients:
##      ar1      ar2      sma1
##      0.930  -0.259  0.287
## s.e.  0.073   0.073  0.067
##
## sigma^2 = 0.402: log likelihood = -171.8
## AIC=351.6 AICc=351.9 BIC=364.4
lmtest::coeftest(sarima)
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1      0.9302     0.0732  12.70 < 2e-16 ***
## ar2     -0.2589     0.0731  -3.54 4e-04 ***
## sma1      0.2871     0.0672   4.27 1.9e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

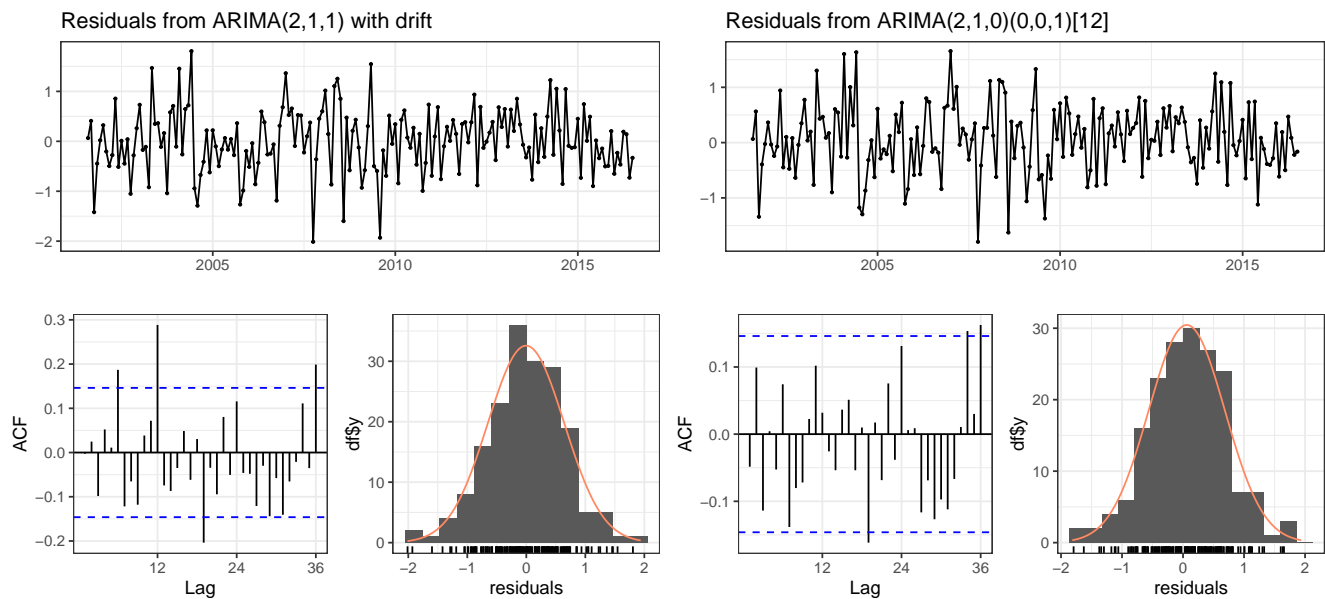
4. Cheque a qualidade do ajuste do(s) modelo(s) selecionado(s) no item anterior e explique cada os resultados obtidos para avaliar a qualidade do ajuste.

(a) Qual a conclusão do teste de Ljung e Box (apresente as hipótese)? Comente.

(b) Apresente os gráficos do diagnóstico. Interprete e comente.

Gráficamente, os resíduos parecem com ruído branco por serem independentes e normalmente distribuídos, as autocorrelações entre os resíduos só são significantes para alguns lags altos.

```
checkresiduals(arima, test = FALSE)
checkresiduals(sarima, test = FALSE)
```



Verificando a independência dos resíduos do modelo pelos testes de Box-Pierce e Box-Ljung, não rejeitamos a hipótese de que os resíduos são independentes em ambos os modelos.

```
Box.test(arima$residuals, type = "Box-Pierce")$p.value
## [1] 0.9715
Box.test(arima$residuals, type = "Ljung-Box")$p.value
## [1] 0.9713
Box.test(sarima$residuals, type = "Box-Pierce")$p.value
## [1] 0.5154
Box.test(sarima$residuals, type = "Ljung-Box")$p.value
## [1] 0.5119
```

Também não rejeitamos a hipótese de normalidade dos resíduos, ambos os modelos são válidos.

```
shapiro.test(arima$residuals)$p.value
## [1] 0.6741
nortest::lillie.test(arima$residuals)$p.value
## [1] 0.6683
shapiro.test(sarima$residuals)$p.value
## [1] 0.8816
nortest::lillie.test(sarima$residuals)$p.value
## [1] 0.9531
```

5. Exclua as 12 ultimas observações da série temporal e faça previsão considerando a série truncada (`chicken.truc`).


```
n <- length(chicken)
chicken.trunc <- ts(chicken[1:(n - 12)], freq = 12, start = c(2001, 8))
```

- (a) Considere a série (`chicken.trunc`) e apresente os valores previstos 12 passos a frente considerando os modelos ARIMA/SARIMA. Importante: Note que é preciso buscar novos ajustes/chechar qualidade do ajuste para `chicken.trunc`, e depois fazer as previsões.

A ordem estimada do modelo ARIMA, a significância de seus coeficientes e as hipóteses de independência e normalidade dos resíduos continuam as mesmas.

```
arima.trunc <- auto.arima(chicken.trunc, seasonal = FALSE)
lmtest::coefest(arima.trunc)
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1      1.379      0.162   8.53  < 2e-16 ***
## ar2     -0.622      0.110  -5.66  1.5e-08 ***
## ma1     -0.493      0.198  -2.49   0.0128 *
## drift     0.313      0.107   2.93   0.0034 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
checkresiduals(arima.trunc, test = FALSE)
```

Residuals from ARIMA(2,1,1) with drift



O mesmo acontece para o modelo SARIMA, as ordens estimadas são as mesmas e possui coeficientes não significantes que foram removidos da mesma forma.


```
sarima.trunc <- Arima(
  chicken.trunc,
  order = c(2, 1, 0),
```

```

seasonal = c(0, 0, 1),
include.drift = FALSE,
)
lmtest::coeftest(sarima.trunc)
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1      0.9339     0.0755  12.36 < 2e-16 ***
## ar2     -0.2675     0.0754   -3.55 0.00038 ***
## sma1      0.2960     0.0709   4.17 3e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
checkresiduals(sarima.trunc, test = FALSE)

```

Residuals from ARIMA(2,1,0)(0,0,1)[12]



Os valores previstos dos modelos ARIMA e SARIMA para o ano retirado da série truncada são:

```

arima.predict <- forecast(arima.trunc, h = 12)$mean
sarima.predict <- forecast(sarima.trunc, h = 12)$mean
arima.predict
##      Jan  Feb  Mar  Apr  May  Jun  Jul  Aug  Sep  Oct  Nov  Dec
## 2015                115.8 115.8 116.0 116.3 116.7
## 2016 117.1 117.5 117.9 118.2 118.5 118.8 119.1
sarima.predict
##      Jan  Feb  Mar  Apr  May  Jun  Jul  Aug  Sep  Oct  Nov  Dec
## 2015                115.6 115.6 115.7 115.8 115.8
## 2016 115.9 115.8 115.9 116.0 116.2 116.0 115.9

```

- (b) Considere a série (`chicken.trunc`) e apresente os valores previstos 12 passos a frente considerando o algoritmo de alisamento exponencial.

```
holt <- hw(chicken.trunc)
holt.predict <- forecast(holt, h = 12)$mean
holt.predict
##          Jan   Feb   Mar   Apr   May   Jun   Jul   Aug   Sep   Oct   Nov   Dec
## 2015                                115.7 115.5 114.3 113.3 113.0
## 2016 113.4 114.0 114.6 114.9 115.9 116.9 117.6
```

- (c) De acordo com as características da série, utilize os métodos simples de previsão considerando a série **chicken.truc** e apresente os valores previstos 12 passos a frente.

O método de média global não é válido pois a série possui tendência e o Naïve não é adequado pois a série truncada acaba no auge da sazonalidade, assim as previsões serão mais altas que o normal.

```
snaive <- snaive(chicken.trunc, h = 12)
snaive.predict <- forecast(snaive, h = 12)$mean
snaive.predict
##          Jan   Feb   Mar   Apr   May   Jun   Jul   Aug   Sep   Oct   Nov   Dec
## 2015                                112.8 113.5 113.9 113.9 113.8
## 2016 114.1 113.8 114.3 114.9 116.0 116.0 115.9
```

```
sma <- smooth::sma(chicken.trunc, order = 6, h = 12)
sma.predict <- forecast(sma, h = 12)$mean
sma.predict
##          Jan   Feb   Mar   Apr   May   Jun   Jul   Aug   Sep   Oct   Nov   Dec
## 2015                                115.1 115.4 115.5 115.6 115.6
## 2016 115.5 115.5 115.5 115.5 115.6 115.5 115.5
```

- (d) Calcule e compare os erro quadrático médio e o erro médio percentual (ver função **accuracy**) das previsões obtidas via modelos ARIMA, alisamento exponencial e métodos simples de previsão (utilizados no item anterior). O que você pode concluir?

```
verdadeiro <- ts(chicken[(n - 11):n], freq = 12, start = c(2015, 8))
```

Para previsão de 12 passos a frente, os modelos ARIMA e SARIMA tiveram pior raiz do erro quadrático médio e média do erro absoluto percentual, o método de alisamento exponencial de Holt-Winters e Naïve sazonal obtiveram os menores erros.

O método de Naïve sazonal obteve a menor raiz do erro quadrático médio.

```
yardstick::rmse_vec(verdadeiro, arima.predict)
## [1] 5.076
yardstick::rmse_vec(verdadeiro, sarima.predict)
## [1] 3.34
yardstick::rmse_vec(verdadeiro, holt.predict)
## [1] 2.935
yardstick::rmse_vec(verdadeiro, snaive.predict)
## [1] 2.691
yardstick::rmse_vec(verdadeiro, sma.predict)
## [1] 3.007
```

O método de Holt-Winters obteve a menor média do erro absoluto percentual.


```
yardstick::mape_vec(verdadeiro, arima.predict)
## [1] 3.978
yardstick::mape_vec(verdadeiro, sarima.predict)
## [1] 2.671
yardstick::mape_vec(verdadeiro, holt.predict)
## [1] 1.869
yardstick::mape_vec(verdadeiro, snaive.predict)
## [1] 2.052
yardstick::mape_vec(verdadeiro, sma.predict)
## [1] 2.41
```